

سوال اول :

(الف)

زادیه	$r=0$	$r=1$	$r=2$	
0	10	7	-	$\rightarrow 17$
45	7	8	2	$\rightarrow 17$
90	12	5	-	$\rightarrow 17$
135	5	9	3	$\rightarrow 17$

$\Rightarrow$

$10+8+5+3$	$10+7+12+9$
$7+2+5+9$	$7+8+12+5$

$\Rightarrow$

26	38
23	32

جبدل بدست آمده حاصل عبارت  $(N-1)\mu(m,y) + \iint \mu(m,y) dxdy$  است

بنابراین برای بدست آوردن  $\mu(m,y)$  ،  $\iint \mu(m,y) dxdy$  را کم دهی به  $N-1$  قسمی کنی

$$\begin{array}{|c|c|} \hline 9 & 21 \\ \hline 6 & 15 \\ \hline \end{array} \xrightarrow{\div 3} \begin{array}{|c|c|} \hline 3 & 7 \\ \hline 2 & 5 \\ \hline \end{array}$$

(ب) با توجه به اعداد بدست آمده ، عدد 7 که بزرگتر است (جذب بیشتری) احتمالاً مربوط به

استخوان و عدد 2 ، که کمتر است احتمالاً مربوط به هوا است .

**ج** در روش back projection به دلیل انجام محاسبات پیچیده ، سرعت کافی به ویژه برای

dataset های بزرگ ، این روش قابلیت حذف noise ندارد و گاهی به تصویر خروبی بازسازی شده منجر می شود

این موضوع باعث کاهش کیفیت تصویر و در نتیجه سخت شدن تفسیر نتایج می شود . این روشی نیازمند ذخیره پرده های تکرار


شده در دست بایست ملاحظه کنید ، این روشی اصلاً است و هیچ موضوع به ب است . زیاد این روشی از حالت قطعی می شود .







سوال سوم:



$$\mu_1(u) = 2u^2, \quad \mu_2(u) = u+3, \quad \mu_3(u) = \frac{1}{u^2+1}$$

$$I_0 = I_{in} e^{-\int_{u_{in}}^{u_0} \mu(u) du} \Rightarrow N_1 = N_0 e^{-\int_0^{L_1} \mu_1(u) du} = N_0 e^{-\int_0^{L_1} 2u^2 du} = N_0 e^{-\frac{2}{3}u^3 \Big|_0^{L_1}}$$

$$\Rightarrow N_1 = N_0 e^{-\frac{2}{3}(L_1)^3}$$

$$N_2 = N_1 e^{-\int_0^{L_2} \mu_2(u) du} = N_1 e^{-\int_0^{L_2} (u+3) du} = N_1 e^{-\left(\frac{u^2}{2} + 3u\right) \Big|_0^{L_2}} = N_1 e^{-\left(\frac{(L_2)^2}{2} + 3L_2\right)}$$

$$N_3 = N_2 e^{-\int_0^{L_3} \mu_3(u) du} = N_2 e^{-\int_0^{L_3} \frac{1}{u^2+1} du} = N_2 e^{-\tan^{-1}(u) \Big|_0^{L_3}} = N_2 e^{-\tan^{-1}(L_3)}$$

$$\Rightarrow N_3 = \left( N_0 e^{-\frac{2}{3}(L_1)^3} \right) \cdot e^{-\left(\frac{(L_2)^2}{2} + 3L_2\right)} \cdot e^{-\tan^{-1}(L_3)}$$

$\underbrace{\hspace{10em}}_{N_1} \quad \underbrace{\hspace{10em}}_{N_2}$

سوال چهارم:

① مزیت این روش این است که می تواند زمان تصویر برداری را خاصیتی دهد بدون اینکه اطلاعات

بالایی تشخیص داده شده را از دست دهد. به طوری که زمان PET scan را از 20 الی 45 دقیقه برای کل

بدن به 20 الی 30 دقیقه خاصیتی دهد.



②

الف) سه مدل در مقاله مورد بررسی قرار گرفته که ورودی یکی از کال ها تصویر PET 2.5d سه کاناله است

و ورودی در مدل دیگر ترکیب دو تصویر PET 2.5d و CT 2.5d است که یک تصویر سه کاناله شکل

می دهند. خروجی مدل ها نیز تصویر بازسازی شده PET معادل حالت Full time خواهد بود.

ب) در این مقاله از یک مدل تقسیم یافته GAN به نام Pix2PixHD استفاده شده است. این مدل

تقسیم یافته مدل اصلی Pix2Pix است با این تفاوت که از دو generator استفاده می کند که با

رزولوشن های مختلف کار می کنند. ویژگی های local, global تصویر را جمع کاری کنند. discriminator این

مدل یک multi-scale discriminator است که خود متشکل از سه discriminator جدا است که هر

کدام روی scale های متفاوتی از تصویر اجزای شوند.

ج) در این مقاله از معیارهای ارزیابی متفاوتی استفاده شده است. همگی مدل ها بر روی 200 مطالعه آزمایی

و با استفاده از معیارهای ارزیابی  $\text{Peak Signal to Noise Ratio}$  ،  $\text{Similarity Index Measure}$  ،

$\text{SUV-based Mean Absolute Error}$  ارزیابی شده اند.

در مرحله بعد 50 مورد از 200 مطالعه آزمایی به صورت random انتخاب و به صورت دستی توسط متخصص

آزمایی می شود. فرد تعدادی Fulltime PET و AI-Extreme PET را segments می کند.

در نتیجه یک مجموعه از 50 تا تصویر segmented mask از مرکز کلم از تعدادی Fulltime-PET و

AI-Extreme-PET خواص داشت که با بررسی اشکالات میان این دو تصویر برای هر نمونه، خروجی مدل ارزیابی می شود.



با توجه به نتایج بدست آمده ، مدل M3 در ارزیابی های اینم شده عملکرد بهتری داشته است . در این مدل

مردود تصویر PET و CT به عنوان ورودی مدل داده شده و از یک ساختار group convolution استفاده می کنند .

## سؤال ششم :

① شبکه های عصبی عمیق زمانی که در معرض noise قرار می گیرند ، می توانند دچار خطا ، اشتباه در

classification شوند . داده های تعدادی پزشکی نیز بدون noise نیستند ، شامل تلف گسترده ای از attenuation ها

هستند . در فرایند حذف نویز مدل قابل توجهی از جزئیات از بین می رود . مدل باید در برابر عمل های adversarial کار کند

باشد ، زیرا اگر این گونه نباشد ، در صورت حذف خطای مدل افزایش یافته در نتیجه نمی تواند اعتماد کافی را جذب کند .

② یک مجموعه از داده ی پزشکی باید شامل metadata ، identifier و حجم مناسبی از تعدادی باشد که توسط متخصص

تحلیل شده اند تا مجوز توزیع و قابل استفاده بودن در مطالعات را پیدا کند . جمع کردن چنین داده ای بسیار زمان بر و پرهزینه

است . مکتب چنین داده هایی بسبب شده تا روش های یادگیری عمیق با محافظت در دسترسند . برای مقابله با این مشکل از

روش های data augmentation استفاده می شود . در این روش ها با ایجاد تغییراتی در داده اصلی بدون از دست دادن feature ها

داده های بیکیتری تکثیر می شود . برخی از این روش ها عبارتند از : flipping ، translation ، random crop ، rotation ،

... . از آنجایی که این روش ها تصویر جدیدی تولید نمی کنند ، امکان overfit در مدل افزایش می یابد . برای حل این مشکل

از روش های GAN ، autoencoder ها در یادگیری عمیق استفاده می شود .



③ مهم‌های روش‌های یادگیری عمیق برای عدم دشوار است. از طرفی به دلیل اهمیت نتایج این مدل‌ها باید

معیارهای مناسبی برای ارزیابی آن‌ها وجود داشته باشد.  $F1 score$ ,  $recall$ ,  $precision$ ,  $accuracy$  معیارهای

عددی برای ارزیابی مدل هستند اما آن‌ها کافی که این مقادیر قابل دستکاری هستند، مورد اعتماد عدم نیستند. همین موضوع بس

شده تا نیازمند روش‌های  $visual\ explainability$  باشیم تا افراد بتوانند عملکرد الگوریتم‌های یادگیری عمیق را درک کنند.

این روش‌ها برای افراد قابل فهم‌تر و جذاب‌تر از معیارهای عددی هستند. برخی از این روش‌ها عبارتند از

$LIME$  ,  $Gradient-based\ CAM$  ,  $Local\ Interpretable-Model\ Agnostic\ Explaners$  ,  $Class\ Activation\ Maps$  ,  $CAM$

$W&T$ ,  $SHAP$

④ روش‌های  $model\ agnostic$ ، مستقل از مدل یا معماری کان هستند به همین دلیل انعطاف

پذیری بالایی دارند و بدون اینکه معیار ارزیابی متفاوتی برای هر مدل ارائه شود، می‌توانند نتایج مطلوبی

برای انواع مختلف الگوریتم‌ها و معماری‌های مدل‌های مصنوعی تولید کنند. یک روش مورد اعتماد  $model\ agnostic$

که مورد تأیید متخصصان باشد، می‌تواند به عنوان یک روش استاندارد مورد استفاده قرار بگیرد. همین موضوع باعث می‌شود که

به توان کان ما به راحتی برای افراد عادی توضیح داد و با روش‌های قابل اعتماد دیگر مقایسه کرد.

در مقابل روش‌های  $model\ specific$ ، نمی‌توانند طیف زیادی از مدل‌ها را توضیح دهند، انعطاف‌پذیری

کمتری دارند اما توضیحات خاص‌تر و دقیق‌تر و کامل‌تری ارائه می‌دهند زیرا برای یک مدل یا معماری خاص طراحی

شده‌اند و برای توسعه و پیاده‌سازی هر مدل نیازمند تلاشی زیادی هستند.