خسته نباشید

Subject: تمرین چهارم تحلیل هوشمند تصاویر پزشکی

Year. Month. Date. ( ) 402 212 214 سیاوش کسائی

سوال اول: همفکری با امیرمحمد عزتی، سروش وفایی تبار

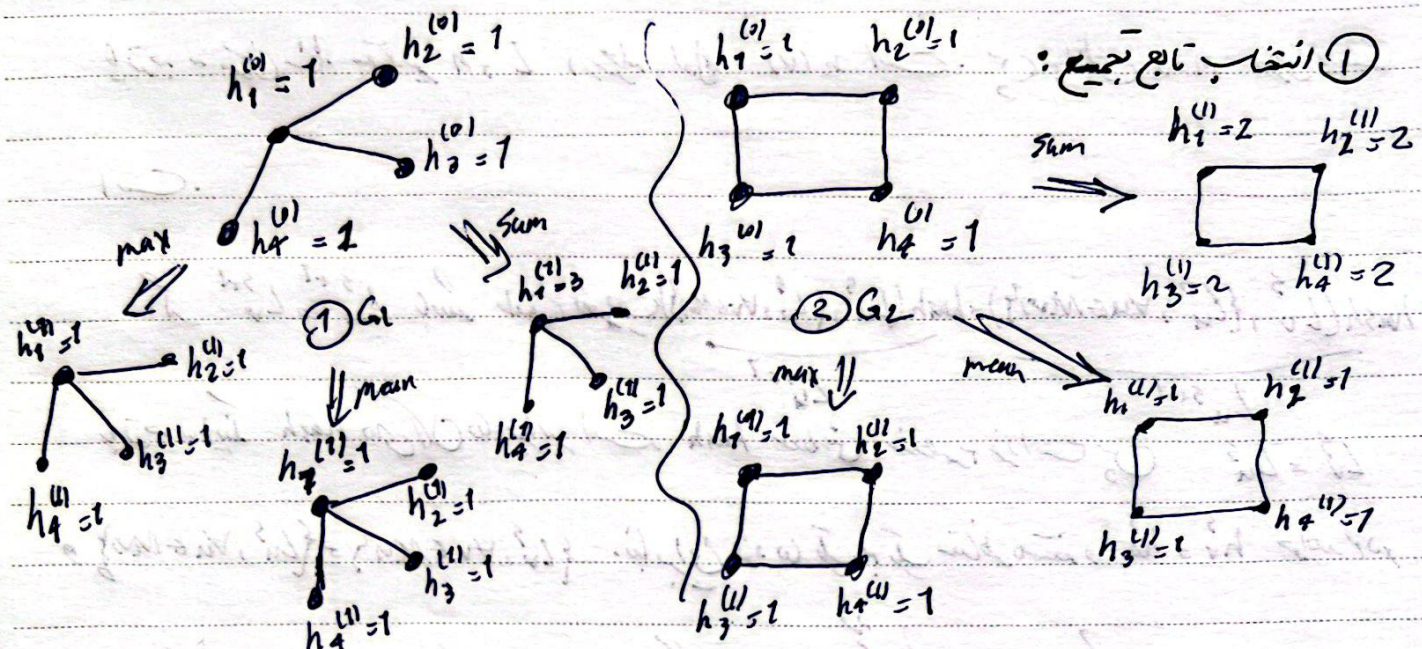

تابع های max, mean برخلاف تابع sum به تعداد ورودی ها وابسته نیستند. بنابراین

در حالت ② با $h_i^{(0)}$ برابر برای گره های دو گراف مانند گراف های بالا (با تعداد گره مساوی)

مقادیر max, mean و در نتیجه ستار $h_i^{(1)}$ مانند حالت قبل خواهد شد. اما برای تابع

sum اینگونه نیست.

② کارسول و اینیالیر-لمن اثبات با استفاده از برهان خلف ← فرض خلف

← WL تصمیم نگیرد گراف ها ایزومورف اند

فرض خلف زمانی برقرار است که دو مجموعه $\{L_v^{(k)}, \forall v \in V_1\}$ و $\{L_v^{(k)}, \forall v \in V_2\}$ برابر باشند.

اگر این فرض به برابر بودن Rank ها برسیم، به تناقض خواهیم رسید.

با توجه به اینکه L ها نتیجه Hash هستند، information loss بزرگی دارند. بنابراین ثابت کنیم

برابر L های دو گراف به برابر h های آن ها نتیجه می دهد.

Subject:
Year. Month. Date. ( )

اثبات با استقرا: به ازای هر $K>m$ داریم، اگر $L_u^m = L_v^m$ باشد، آنگاه $h_u^m = h_v^m$ ⇐ فرض

با توجه به فرض مسئله مقادیر h و L در مرحله اول $n(v)$ است. پس به ازای $m=0$ فرض درست

است.

اگر $L_u^{s+1} = L_v^{s+1}$ باشد طبق تعریف $\underbrace{hash(L_v^s, \{L_u^s, \forall u \in N(v)\})}_{L_u^{s+1}} = \underbrace{hash(L_u^s, \{L_v^s, \forall v \in N(u)\})}_{L_u^{s+1}}$

با توجه به اینکه hash های کل ها برابر است hash مقدارش منحصر به فرد است پس $L_v^s = L_u^s$

و $\{L_v^s, \forall v \in N(u)\} = \{L_u^s, \forall u \in N(v)\}$. بنابراین نود ها یک به یک متناظر هستند و $h_v^s = h_u^s$ خواهد بود

$\{h_v^s, \forall v \in N(v)\} = \{h_u^s, \forall u \in N(u)\}$. بنابراین اگر مقادیر h های نود های دو گراف برابر باشد، حاصل مقدار تابع

Aggregation کل ها نیز برابر و در نتیجه حاصل تابع Combine کل ها نیز برابر خواهد بود.

در نتیجه readout کل ها نیز یکسان خواهد شد که متناقض با فرض مسئله است.

بنابراین حکم اثبات می شود.

Subject:
Year. Month. Date. ( )

سؤال دوم:

Hierarchical Graph Representation in Digital Pathology:

① رویکرد نوآورانه ارائه شده، توسعه یک نمایش entity-graph سلسله مراتبی چندسطحی (Hact) و اجرای یک شبکه عصبی گرافی سلسله مراتبی (Hact-Net) برای تجزیه و تحلیل تصاویر بافت شناسی است. این رویکرد امکان encode کردن جامع microenvironment های سلول و بافت را فراهم می‌کند و نمایش دقیق و جامع‌تری از ترکیب بافت ارائه می‌دهد. این روش با گرفتن ترکیبات سلسله مراتبی موجودیت های بافت شناسی و تعاملات داخلی و خارجی آن ها، درک جامع‌تری از ساختار بافت ارائه می‌دهد که برای تشخیص دقیق سرطان بسیار مهم است.

اکثر روش های موجود پیشین از شبکه های عصبی کانولوشنی به شکل patch-wise استفاده می‌کنند که اطلاعات مربوط به محل بافت را در نظر نمی‌گیرد و فقط اطلاعات patch-level محلی را مورد استفاده قرار می‌دهد. همچنین روش های قبلی معمولاً از یک رویکرد single-stream در طبقه‌بندی تصاویر بافت شناسی استفاده می‌کنند. در مقابل، در روش ارائه شده از یک نمایش گراف موجودیت سلسله مراتبی (Hact) استفاده می‌کند که اطلاعات مربوط به سلول و بافت را encode می‌کند و همچنین از شبکه عصبی سلسله مراتبی گرافی استفاده می‌کند. در نتیجه این کار ورودی نمایش گرافی را به صورت سلسله مراتبی پردازش می‌کند. بنابراین رویکرد جامع‌تری برای تجزیه و تحلیل ترکیب بافت ارائه می‌دهد.

② Hact-Net تصاویر بافت شناسی را با استفاده از معماری شبکه عصبی گرافی سلسله مراتبی برای طبقه‌بندی پردازش می‌کند. این مدل به شیوه سلسله مراتبی بر روی نمایش گراف سلسله مراتبی سلول به بافت (Cell to tissue (Hact)) از سطح سلول ظریف تا سطح ناحیه بافت درشت عمل می‌کند. هدف این شبکه بدست آوردن یک contextualized graph embedding که توزیع مورفولوژی و توپولوژی موجودیت های بافت را encode می‌کند. سپس این embedding برای طبقه‌بندی گراف ورودی

Subject:
Year. Month. Date. ( )

استفاده می‌شود، به شبکه Hact-Net اجازه می‌دهد تا به طور مؤثر تصاویر بافت‌شناسی را بر اساس نمایش‌های گراف سلسله‌مراتبی تجزیه و تحلیل و طبقه‌بندی کند.

SlideGraph+ :

① در مدل SlideGraph+، embedding ویژگی‌های نودهای موجود در شبکه عصبی گرافی به یک لایه خطی یک‌لایه متناظر تا پیش‌بینی سطح node را ایجاد کند. منتقل می‌شود. این prediction score های node-level برای ایجاد پیش‌بینی WSI-level با هم ترکیب می‌شوند.

روش‌های مبتنی بر patch، تگ‌های محلی کوچک یک تصویر را تحلیل می‌کنند و ممکن است ساختار کلی بافت را در نظر نگیرند. در بسیاری از موارد فقط برچسب مربوط به WSI-level در دسترس است. SlideGraph+ این چالش را با مدل‌سازی ارتباط هر patch با یک label خاص برطرف می‌کند. در این روش با ایجاد پیش‌بینی node-level، نه تنها score مربوط به prediction کلی را مشخص می‌کند، بلکه گره‌های فعال گراف را نیز شناسایی می‌کند که منجر به score کل تصویر شده‌اند. این موضوع مدل را تفسیرپذیرتر می‌کند و بینش‌هایی در مورد مناطق خاص که روی پیش‌بینی تأثیرگذار ارائه می‌دهد.

② مدل رگرسیون چگالی DAB در SlideGraph+ وضعیت HER2 را با تخمین چگالی رنگ کاربری در تصاویر رنگ‌آمیزی شده با H&E پیش‌بینی می‌کند (بررسی شدت DAB staining). این موضوع بسیار مهم است زیرا مدل می‌تواند با بررسی شدت DAB intensity، سطح HER2 را تعیین کرده و وضعیت آن را در نمونه بافت مشخص کند و این کار را به صورت سیستم و بدون نیاز به رنگ‌آمیزی ایمونوهیستوشیمی افزایشی (IHC) انجام می‌دهد و نیاز بالقوه به آن را از بین می‌برد. به طور معمول IHC برای ارزیابی وجود گیرنده‌های پروتئینی خاص مانند HER2 انجام می‌شود. این رویکرد کارایی و دقت پیش‌بینی در وضعیت HER2 را بهبود می‌بخشد.

Subject:
Year. Month. Date. ( )

سوال سوم:

ViT-V-Net:

یکی از محدودیت های VoxelMorph این است که به شبکه های کانولوشن محلی متکی است و ممکن است روابط long-range spatial در تصاویر را به طور کامل ثبت نکند. (برای مثال دو voxel که از هم فاصله مکانی دارند) و این موضوع به دلیل local بودن عملیات مربوط به کانولوشن است.

مدل ارائه شده در این مقاله با استفاده از یک ساختار ترکیبی از ConvNet و Transformer محدودیت موجود در VoxelMorph حل می کند. در این روش ViT برای ویژگی های high level اعمال شده تا مدل را ملزم به یادگیری روابط long-range در تصویر کند.

هر دو مدل از ساختار کانولوشن (encoder, decoder) استفاده می کنند با این تفاوت که در مدل ViT-V-Net، به جای استفاده از U-Net ساده، بعد از تبدیل داده ورودی به ویژگی های high-level توسط لایه های کانولوشن (encoder)، از مدل ViT استفاده شده که در آن این ویژگی ها را به vector های تبدیل و سپس به لایه latent تحویل می دهد. به هر کدام از embed های patch ها positional embeddings اضافه شده و سپس با استفاده از یک transformer encoder شامل لایه های Multihead self attention و Multi-layer perception، encode شده و بعد از reshape کردن خروجی ViT توسط یک V-Net decoder decode می شود. همچنین در هر دو مدل از spatial transformation function استفاده شده است تا تصویر warp شده را تولید و بر اساس آن loss محاسبه بشود. در معماری هر دو مدل نیز از skip connection بهره گرفته شده است.

ورودی هر دو مدل نیز stack شده تصویر moving و fixed است.

Subject:
Year. Month. Date. ( )

TransMorph : مدل‌های کانولوشن در مدل‌سازی روابط spatial long range (روابط میان دو voxel که از هم دور هستند) در یک تصویر محدودیت‌هایی به دلیل localizing عملیات کانولوشن دارند. معماری‌های U-Net یا V-Net برای حل این مشکل ارائه شدند که با down sampling و up sampling که از نظر تئوری باعث بزرگ شدن receptive field در ConvNet های می‌شوند، سعی در رفع این محدودیت داشتند. با این حال چند مشکل باقی می‌ماند. اول اینکه، receptive field لایه‌های اول همچنان توسط اندازه kernel محدود شده‌اند و اطلاعات global تصویر فقط در لایه‌های عمیق‌تر قابل مشاهده است. دوم اینکه با عمیق شدن لایه‌های ConvNet، تأثیر voxel هایی که دور از یکدیگر هستند کاهش می‌یابد. بنابراین receptive field معماری U-Net در عمل بسیار کوچکتر از حالت نظری آن است. همین موضوع سبب محدودیت U-Net در نتیجه VoxelMorph در درک اطلاعات semantic و مدل‌سازی روابط long-range بین نقاط می‌شود. در مقابل transformer ها به دلیل داشتن receptive field بزرگ‌تر و مکانیزم self-attention، توانایی حل این مشکل را دارند. مدل ارائه شده در این مقاله نیز از یک ترکیب Transformer-ConvNet، با نام TransMorph استفاده می‌کند که از یک encoder بر مبنای Swin Transformer برای ثبت spatial correspondence میان تصویر moving و fixed استفاده می‌کند. سپس یک decoder بر مبنای ConvNet اطلاعات خروجی transformer را decode و تحویل لایه بعدی می‌دهد. همچنین از long skip connection نیز برای حفظ جریان اطلاعات localization میان encoder و decoder استفاده شده است. در این مقاله اشاره شده که مدل ارائه شده به positional coding نیاز ندارد و مدل ارائه شده از receptive field بزرگ‌تری نسبت به ConvNet مورد استفاده در VoxelMorph یا UNet برخوردار است.

Subject:
Year. Month. Date. ( )

هر دو مدل از ساختار کانولوشنی متشکل از encoder, decoder استفاده می‌کنند و ورودی‌شان ما زوج عکس moving, fixed است با این تفاوت که در مدل TransMorph، از یک مدل ترکیبی از ساختار Transformer, ConvNet استفاده می‌کند، در نتیجه استفاده از مدل Swin Transformer عملکرد مدل در یافتن روابط long range بهبود پیدا می‌کند.